Reconstrucción de parámetros de un plasma toroidal por medio de Metropolis-Hastings

Isaac Flores Ureña - C32982*
Escuela de Física, Universidad de Costa Rica
(Dated: 27 de octubre de 2026)

1. Pregunta de investigación

¿Es posible reconstruir los parámetros geométricos y de presión a partir del modelo de Solov'ev-Cerfon-Freidberg de un plasma toroidal en equilibrio con datos sintéticos y ruidosos usando un algoritmo de Metropolis-Hastings, y qué tan bien se recontruyen estos parámetros al comparar con los valores originales?

2. Justificación

La reconstrucción del equilibrio de un plasma confinado magnéticamente es un problema central en el análisis de datos de experimentos de fusión nuclear. Dado que las cantidades físicas internas del plasma (presión, corriente, geometría de las superficies de flujo magnético) en general no pueden medirse de forma directa, estas deben inferirse a partir de mediciones externas, lo cual convierte a la reconstrucción de equilibrio en un problema de inferencia estadística antes que en un simple cálculo determinista. En dispositivos reales como tokamaks y stellarators, este proceso se suele realizar mediante marcos de inferencia bayesiana que combinan múltiples diagnósticos para estimar el estado físico del plasma junto con su incertidumbre asociada [1][2].

La ventaja de este enfoque es que, en lugar de un único valor para cada parámetro, entrega su distribución de probabilidad, lo que permite cuantificar la incertidumbre y las correlaciones entre parámetros. Su costo es que los métodos de muestreo como Metropolis-Hastings requieren evaluar el modelo directo miles de veces, y este usualmente exige resolver la ecuación de Grad-Shafranov mediante métodos numéricos de volúmenes o elementos finitos, lo que hace inviable el muestreo. Esta limitación ha motivado en la literatura distintas estrategias, desde sustitutos basados en redes neuronales [2] hasta el uso de soluciones analíticas cerradas de la ecuación de Grad-Shafranov bajo perfiles simplificados de presión y corriente, como la solución de Solov'ev extendida por Cerfon y Freidberg [3].

Este trabajo opta por la segunda opción. Con esta solución, cada evaluación del modelo se reduce a resolver un sistema lineal de 7×7, por lo que es posible generar del orden de 10^4 a 10^5 muestras sin un equipo de cómputo de alto rendimiento y sin entrenar un modelo sustituto. Además, esta solución describe tokamaks convencionales y esféricos con razón de aspecto, elongación y triangularidad arbitrarias [3], lo que permite comparar la reconstrucción en configuraciones de distintos dispositivos.

El modelo es una simplificación (los perfiles de presión y de corriente poloidal son lineales en el flujo), pero su valor está en servir como banco de pruebas controlado del problema de inferencia. Con un modelo directo barato es posible caracterizar la distribución posterior completa de los cuatro parámetros (ε, κ, δ, A) y estudiar qué tan bien los determina cada tipo de observación y qué correlaciones o degeneraciones aparecen entre ellos, algo difícil de explorar cuando cada evaluación del modelo es costosa. Además, como los datos se generan con el mismo modelo que se usa para reconstruir, no existe error de modelo, de modo que la calidad de la reconstrucción obtenida es una referencia del mejor caso: si un parámetro no puede recuperarse en estas condiciones ideales, difícilmente podrá recuperarse con datos reales.

Por último, el uso de datos sintéticos es una decisión metodológica deliberada. Además de la dificultad de acceder a mediciones reales, permite conocer el valor exacto de los parámetros con los que se generaron las observaciones y, con esto, evaluar de forma cuantitativa la calidad de la reconstrucción, algo que no es posible con datos experimentales, donde el estado verdadero del plasma es justamente lo que se desconoce.

3. Objetivos

Objetivo principal

- Reconstruir los parámetros geométricos y de presión de un plasma toroidal en confinamiento cinético que se encuentra en equilibrio usando la solución analítica de Solov'ev-Cerfon-Freidberg como modelo, através de un algoritmo de Metropolis-Hastings.

*Electronic address: isaac.floresurena@ucr.ac.cr

Objetivos específicos

- Crear datos sintéticos que emulen mediciones experimentales usando la solución de Solov'ev-Cerfon-Freidberg y ocultarlos añadiendo ruido gaussiano.
- Probar con diferentes parámetros iniciales (parámetros a priori) para probar la convergencia y capacidad de reconstruir los datos sintéticos ocultos usando el algoritmo de Metropolis-Hastings.
- Comparar la reconstrucción de varias configuraciones de reactores reales para visualizar la eficacia de esta implementación en diferentes condiciones.

4. Marco Teórico

Para el estudio de plasmas, por lo general se busca encontrar simetrías geométricas para obtener alguna variable cíclica que no afecte a las cantidades físicas que se quieren calcular. De esta manera, por ejemplo, se puede pasar de una cantidad que dependa de tres variables a una que solo dependa de dos. En el caso particular en donde hay simetría axial bajo un sistema de coordenadas cilíndricas, la coordenada cíclica es la parte azimutal ($\frac{\partial}{\partial\phi} = 0$).

Esto es especialmente útil al trabajar con plasmas que están en confinamiento cinético como en un Tokamak, donde esta simetría axial se ve presente. Cuando un plasma presenta este tipo de simetría y se considera que es ideal y en estado estacionario, el cambo magnético $\mathbf{B}$ se puede expresar de la siguiente forma [4]:

$$\mathbf{B} = \frac{F(\Psi)}{R}\mathbf{e}_\phi + \frac{1}{R}\nabla\Psi \times \mathbf{e}_\phi \tag{1}$$

con $\Psi = \Psi(r, z)$ como el flujo poloidal, $F(\Psi)$ relacionado a la componente toroidal del campo ($F(\Psi) = B_\phi r$). A su vez, por las ecuaciones de Maxwell, tenemos una relación entre el campo magnético $\mathbf{B}$, la densidad de corriente $\mathbf{J}$ y el gradiente de la presión térmica ($\mathbf{J} \times \mathbf{B} = \nabla p$).

4.1. Ecuación de Grad-Shafranov (GS)

En el estudio analítico de plasmas, el caso particular en donde este tiene simetría axial en coordenadas cilíndricas, y que está en estado estacionario (equlibrio). Si un plasma cumple con la simetría antes descrita y está en un estado estacionario, su comportamiento está dado por la siguiente ecuación diferencial elíptica de su flujo en 2 dimensiones [4]:

$$r\frac{\partial}{\partial r}\left(\frac{1}{r}\frac{\partial\Psi}{\partial r}\right) + \frac{\partial^2\Psi}{\partial z^2} = -\mu_0 r^2\frac{dp}{d\Psi} - F\frac{dF}{d\Psi} \tag{2}$$

con $p = p(\Psi)$.

Siguiendo el procedimiento de [3] (el cual será la base de la solución analítica para este trabajo), se normaliza la ecuación 2 con las relaciones $r = R_0 x$, $z = R_0 y$ y $\Psi = \Psi_0\psi$ junto con las superficies de flujo poloidal de la solución analítica de Solov'ev [5], se obtiene la ecuación diferencial:

$$x\frac{\partial}{\partial x}\left(\frac{1}{x}\frac{\partial\psi}{\partial x}\right) + \frac{\partial^2\psi}{\partial y^2} = (1-A)x^2 + A \tag{3}$$

$$A = -\frac{R_0^2}{\Psi_0^2}F\frac{dF}{d\psi} \quad ; \quad C = -\mu_0\frac{R_0^4}{\Psi_0^2}\frac{dp}{d\psi} \tag{4}$$

Con R_0 el radio mayor del plasma y Ψ_0 una constante arbitraria que haga que A y C cumplan $A + C = 1$, con estas dos cantidades de igual manera constantes. De esta forma, A estaría relacionada con el parámetro β [3], que es la razón entre la presión térmica y la presión magnética.

$$\beta = \frac{p}{B^2/2\mu_0} \tag{5}$$

La solución general propuesta por [3] es la siguiente,

$$\psi(x, y) = \frac{x^4}{8} + A\left(\frac{x^2 lnx}{2} - \frac{x^4}{8}\right) + \sum_{i=1}^{7} c_i\psi_i \tag{6}$$

con ψ_i:

$$\begin{cases} \psi_1 = 1 \ ; \ \psi_2 = x^2 \ ; \ \psi_3 = y^2 - x^2 lnx \\ \psi_4 = x^4 - 4x^2y^2 \\ \psi_5 = 2y^4 - 9y^2x^2 + 3x^4 lnx - 12x^2y^2 lnx \\ \psi_6 = x^6 - 12x^4y^2 + 8x^2y^4 \\ \psi_7 = 8y^6 - 140y^4x^2 + 75y^2x^4 - 15x^6 lnx + ... \\ \qquad 180x^4y^2 lnx - 120x^2y^4 lnx \end{cases} \tag{7}$$

Las constantes c_i son determinadas por las condiciones de frontera de ψ. Para obtener estas constantes se usan las ecuaciones paramétricas que describen la forma del contorno de un plasma en confinamiento inercial:

$$\begin{cases} x = 1 + \varepsilon cos(\tau + \alpha sin\tau) \ ; \ 0 \le \tau \le 2\pi \\ y = \varepsilon\kappa sin(\tau) \end{cases} \tag{8}$$

Las cuales se aplican usando los siguientes parámetros geométricos: $\varepsilon = a/R_0$, donde a es el radio menor del plasma, κ es la elongación, y $\delta = sin\alpha$ la triangularidad.

Con las siguientes condiciones de frontera se obtienen los coeficientes c_i usando los parámetros geométricos y físicos del plasma ϵ, κ, δ y A [3].

$$\begin{cases} \psi(1+\varepsilon,0)=0 \\ \psi(1-\varepsilon,0)=0 \\ \psi(1-\delta\varepsilon,\kappa\varepsilon)=0 \\ \psi_x(1-\delta\varepsilon,\kappa\varepsilon)=0 \\ \psi_{yy}(1+\varepsilon,0)=-N_1\psi_x(1+\varepsilon,0) \\ \psi_{yy}(1-\varepsilon,0)=-N_2\psi_x(1-\varepsilon,0) \\ \psi_{xx}(1-\delta\varepsilon,\kappa\varepsilon)=-N_3\psi_y(1-\delta\varepsilon,\kappa\varepsilon) \end{cases} \tag{9}$$

con los coeficientes N_1, N_2 y N_3 definidos como:

$$N_1 = -\frac{(1+\alpha)^2}{\varepsilon\kappa^2} \tag{10}$$

$$N_2 = \frac{(1-\alpha)^2}{\varepsilon\kappa^2} \tag{11}$$

$$N_3 = -\frac{\kappa}{\varepsilon\cos^2\alpha} \tag{12}$$

4.2. Inferencia Bayesiana

Sea H un conjunto de parámetros que pertenecen a un modelo, estos van a tener relacionados una serie de datos D que son observables y/o medibles. En muchos casos, estos parámetros H no son conocidos, entonces se tienen que inferir dados los datos que se obtienen de los resultados que estos producen. Para atacar este tipo de problemas hay múltiples técnicas, sin embargo muchas de estas en el campo de la física nuclear recaen en el concepto de inferencia Bayesiana.

Para realizar esto se toma $P\{H,D\}$ como la distribución de probabilidad de que los parámetros H y los datos D se den al mismo tiempo, o en otras palabras, la probabilidad de la intersección de ambos eventos; $P\{D|H\}$ como la distribución de probabilidad condicional de D dado H; y finalmente $P\{H\}$ como la distribución de probabilidad de H, sin embargo, como no se conoce H, esta distribución de probabilidad es en realidad a "priori", o sea, una aproximación arbitraria a los parámetros reales usando conocimiento previo de su comportamiento. Estas tres cantidades se relacionan de la siguiente forma [2].

$$P\{H,D\} = P\{D|H\}P\{H\} \tag{13}$$

Y definiendo de manera similar pero para $P\{H|D\}$ como la distribución de probabilidad de los parámetros H dados los datos D, junto con la ecuación 13, se obtinene el siguiente resultado.

$$P\{H|D\} = \frac{P\{D|H\}P\{H\}}{P\{D\}} \tag{14}$$

con $P\{D\} = \int P\{D|H\}P\{H\}dH$.

A la ecuacion 14 se le conoce como la fórmula de Bayes, donde $P\{D\}$ es una constante de normalización independiente de H, y que describe la probabilidad de D dados todos los posibles valores de H. A su vez $P\{D|H\}$ se le conoce como una "likelihood function", que está relacionada con el modelo físico que se está trabajando [2]. La importancia de esta ecuación es que da como resultado una medida de la veracidad de los parámetros a priori con los datos observados de manera cuantificable [2].

Si se toma como que D no contiene un único tipo de dato, sino que son diferentes mediciones que proveen datos independientes entre si, y poseen información de los parametros de H, la distribución de probabilidad $P\{D|H\}$ se reescribe como $P\{\{D_i\}|H\}$. Y si se asume que $D_i = D_1, D_2, ..., D_N$ son independientes entre si, la distribución de probabilidad factoriza, obteniendo lo siguiente [1].

$$P\{\{D_i\}|H\} = \prod_{i=1}^{N} P\{D_i|H\} \tag{15}$$

$$\Rightarrow P\{H|\{D_i\}\} = \frac{P\{H\}\prod_{i=1}^{N} P\{D_i|H\}}{P\{\{D_i\}\}} \tag{16}$$

Esta última ecuación siendo la forma de la fórmula de Bayes de interés para este trabajo.

Por último, la distribución posterior $P\{H|\{D_i\}\}$ no suele ser trivial, por lo que suelen ser necesarias técnicas de integración estocástica como las cadenas de Markov de Monte Carlo (MCMC) para poder calcular las distribuciones finales [1].

4.3. Método de Monte Carlo de cadenas de Markov

Los métodos de Monte Carlo de cadenas de Markov (MCMC) son una serie de métodos matemáticos que permiten aproximar la distribución de un vector de variables aleatorias $\mathbf{X}$ donde sus componentes dependen entre sí, solo conociendo su función de masa de probabilidad (PMF) o su función de densidad de probabilidad (PDF) salvo una constante multiplicativa. Esto permite poder conocer el comportamiento de una distribución sin conocer su constante de normalización. El desarrollo de esta sección y la siguiente sobre el algoritmo de Metropolis-Hastings sigue el del capítulo 12 del libro *Simulation*, quinta edición, de Sheldon M. Ross [6].

Sea una colección de variables aleatorias $X_0, X_1, X_2, ...$, donde X_n identifica el estado de un sistema en el tiempo n, y donde el conjunto de estados posibles es $1, 2, ..., N$. Estos estados están relacionados a través de las transiciones entre si, desde un tiempo n con $X_n = i$ a uno $n+1$ con $X_{n+1} = j$ con una probabilidad asociada de que esto ocurra denotada como P_{ij}, que se define como:

$$P_{ij} = P\{X_{n+1} = j \,|\, X_n = i, X_{n-1}, ..., X_0\} \tag{17}$$

Sin embargo, si suponemos que el estado en $n+1$ depende del paso anterior de manera directa solamente, en otras palabras, no le afectan los estados anteriores $X_{n-1}, ..., X_0$, se puede reescribir la probabilidad condicional P_{ij} como:

$$P_{ij} = P\{X_{n+1} = j \,|\, X_n = i\} \tag{18}$$

Estas X_n son una cadena de Markov con probabilidades de transición P_{ij} asociadas si cumple 18, la cual se le llama propiedad de Markov, y se dice que la cadena tiene memoria corta. A su vez, los P_{ij} cumplen que $\sum_{j=1}^{N} P_{ij} = 1$ para cada i, ya que desde cualquier estado el sistema debe pasar a alguno de los estados posibles (o a sí mismo). De esta manera, cada X_n tiene asociado un estado i, y su transición a otro estado está dada de manera aleatoria según las probabilidades P_{ij} antes descritas. Es importante notar que la cadena $\{X_n\}$ es la herramienta que se construye para generar valores, y no el vector $\mathbf{X}$ que se busca simular, o sea la cadena se construye de forma tal que, tras suficientes pasos, sus estados estén distribuidos como $\mathbf{X}$.

4.3.1. Irreducibilidad y probabilidad estacionaria

Una cadena de Markov es irreducible si para cualquier par de estados i, j, en un número finito de pasos, se puede llegar siempre de i a j con una probabilidad positiva. Esto significa que los "nodos"de cada estado pueden comunicarse con todos los demás nodos, en otras palabras, no hay estados aislados del resto, o estados que hagan que la cadena se mantenga en ese punto de manera indefinida (se puede ver como "un pozo o atractor de probabilidad").

A su vez, si una cadena es irreducible, se puede definir una cantidad nueva π_j que representa la proporción de tiempo que el sistema está en el estado j a largo plazo y, con probabilidad 1, no depende del estado inicial. Se puede ver entonces que $\pi_i P_{ij}$ es la proporción de tiempo que la cadena entra al estado j desde i, por lo que las π_j son la solución única del siguiente conjunto de ecuaciones:

$$\pi_j = \sum_{i=1}^{N} \pi_i P_{ij} \quad ; \quad \sum_{j=1}^{N} \pi_j = 1 \tag{19}$$

Estas cantidades π_j reciben el nombre de probabilidades estacionaria de la cadena de Markov, puesto que si el estado inicial se distribuye según las π_j, entonces $P\{X_n = j\} = \pi_j$ para todo tiempo n.

Una propiedad importante de las cadenas de Markov es que si se tiene una función f definida en el espacio de muestras (X_n), el promedio de f evaluado en la cadena tiende al valor de expectación de f con la PMF dada por las π_j.

$$\lim_{m\to\infty} \frac{1}{m} \sum_{i=1}^{m} f(X_i) = \sum_{j=1}^{N} f(j)\pi_j = E\left[f(j)\right] \tag{20}$$

Con esto se pueden aproximar cantidades de importancia como el valor de expectación.

De aquí se ve la utilidad de las cadenas de Markov, puesto que si se tiene un número de pasos lo suficientemente grande, con calcular el lado izquierdo de la ecuación 20, se puede saber información del espacio de estados posibles del sistema, sin conocer completamente la PMF (π_j) de esta.

4.3.2. Aperiodicidad y reversibilidad

Una cadena irreducible es aperiódica si para una en la que el estado inicial es j, hay una probabilidad mayor a 0 de que para un tiempo $n \geq 0$, la cadena pueda estar en el estado j y también su tiempo posterior $n+1$.

$$P\{X_n = j \,|\, X_0 = j\} > 0 \quad \curlywedge \quad P\{X_{n+1} = j \,|\, X_0 = j\} > 0$$

Si esta es aperíodica, entonces $\pi_j = \lim_{n\to\infty} P\{X_n = j\}$, de aquí podemos ver que π_j es la probabilidad límite de la cadena.

Otra clasificación importante son las cadenas reversibles, las cuales son las que cumplen:

$$\pi_i P_{ij} = \pi_j P_{ji} \tag{21}$$

para $i \neq j$. Esta condición se le conoce como balance detallado, y es una condición suficiente (más no necesaria) para que se de una cadena reversible. Esta condición implica que si se empieza la cadena de acuerdo a la probabilidad estacionaria π_j, entonces empezando en cualquier tiempo, ir hacia atrás en el tiempo es también una cadena de Markov con probabilidades de transición P_{ij}.

4.3.3. Probabilidad límite y el estimador

Con todo esto, se puede generar una cadena de Markov cuya probabilidad límite asociada a cada paso es p_j, que aproxime una variables aleatoria X con PMF $P\{X = j\} = p_j$. Con esta cadena, se puede recorrer para m pasos para obtener el valor de X_n, que junto con la ecuación 20 y la ley de los grandes números, se puede estimar cantidades como el valor de expectación de la función $f(X)$ con el estimador de la izquierda de 20.

A este estimador se le suele hacer una pequeña modificación, y es que en la práctica, los primeros resultados de la cadena aún son muy dependientes del estado inicial de la cadena, por lo que se suelen descartar los primeros k pasos antes de realizar los cálculos, quedando de esta manera la siguiente ecuación.

$$\frac{1}{m-k}\sum_{i=k+1}^{m} f(X_i) \approx E\left[f(j)\right] \tag{22}$$

para m grande.

4.4. Algoritmo de Metropolis-Hastings (MH)

El algoritmo de Metropolis-Hastings construye una cadena de Markov reversible donde su probabilidad limite tiende hacia la PMF de una variable aleatoria de interés (por lo general es una PMF muy compleja). Esta PMF desconocida es la probabilidad estacionara $\{\pi_i\}$ vista antes, de manera que al avanzar en la cadena se pueda reconstruir las probabilidades de transición y con ello la distribución original.

Si definimos la probabilidad estacionaria $\pi(j)$ para este caso como:

$$\pi_j = \frac{b_j}{\sum_{j=1}^{N} b_j} = \frac{b_j}{B} \tag{23}$$

donde B véase que es una constante de normalización. Con esto podemos crear la cadena de Markov usando lo siguiente.

Sea $\mathbf{Q}$ una matriz de probabilidades de transición de una cadena de Markov, sus componentes se identifican como q_{ij}. Si definimos una cadena para $\{X_n\}$ con $n \geq 0$, donde para un paso n (llamémosle paso actual) se genera una variable aleatoria X con PMF $P\{X = j\} = q_{ij}$. Entonces para $X = j$ salen dos casos, uno en el que el siguiente paso de la cadena X_{n+1} es igual a j (cambia de estado) con una probabilidad asociada de α_{ij}, o se queda en el mismo estado i, con probabilidad $1 - \alpha_{ij}$ (esto se puede deducir del hecho de que estos son eventos mutuamente exluyentes, por lo tanto la suma de sus probabilidades es 1).

Esto va a formar una cadena de Markov con probabilidades de transición R_{ij} dadas por:

$$R_{ij} = q_{ij}\alpha_{ij}; \quad i \neq j \text{ (cambia de estado)} \tag{24}$$

$$R_{ii} = q_{ii} + \sum_{s \neq i} q_{is}(1 - \alpha_{is}) \quad \text{(se queda igual)} \tag{25}$$

De esta manera se forma una cadena de Markov reversible y con probabilidades estacionarias si se cumple 21 para π_i y R_{ij}.

Usando que $R_{ij} = q_{ij}\alpha_{ij}$, y fijando de manera conveniente que $\alpha_{ji} = 1$, se puede ver que 21 se cumple si:

$$\alpha_{ij} = min(r, 1) = \begin{cases} r & ; \quad \text{si } r < 1 \\ 1 & ; \quad \text{si } r \geq 1 \end{cases} \tag{26}$$

para $r = \frac{\pi_j q_{ji}}{\pi_i q_{ij}}$. A α_{ij} se le conoce como función/tasa de aceptación o criterio de Metropolis.

Con esto, se puede resumir el procedimiento del algoritmo en los siguientes pasos:

1. Escoger una matriz de transiciones $\mathbf{Q}$, junto con algún entero m que será el número máximo de pasos, y otro entero k para definir hasta donde descartar los primero estados de la cadena.
2. Generar una variable aleatoria X con $P\{X = j\} = q_{X_n,j}$ y con esto generar un número aleatorio U (por lo general de una distribución uniforme).
3. Si $U < \frac{b_X q_{X,X_n}}{b_{X_n} q_{X_n,X}}$, entonces $X_{n+1} = X$, sino $X_{n+1} = X_n$
4. Repetir desde 2 hasta llegar a n = m.
5. Descartar los pasos desde $n = 0$ hasta $n = k$.

5. Aplicación de la técnica de Monte Carlo al problema

Reconstruir los parámetros internos de una plasma toroidal es un problema que requiere de probar diferentes configuraciones de los parámetros geométricos de este, para poder obtener el conjunto de parámetros real que calce con los datos experimentales. Estos parámetros no tienen valores discretos, sino que son continuos, y aunado a esto son cuatro de estos, por lo tanto hace falta una forma de aproximar el conjunto de parámetros correcto dentro de todas las posibles combinaciones.

Debido a esto, se recurre a un método de Monte Carlo tipo cadenas de Markov (MCMC), puesto que se pueden

explorar múltiples configuraciones del espacio de muestras de manera aleatoria para probar diferentes configuraciones sin tener que pasar por todas las configuraciones posibles, con lo que se puede obtener una aproximación a estos resultados que permiten inferir cuáles son los parámetros verdaderos. Usando el algoritmo de Metropolis-Hastings, obtener la distribución de probabilidad de este conjunto es posible gracias a que no hay que conocer la probabilidad de que los datos se dieran bajo todas las posibles configuraciones posibles de los parámetros, o sea la normalización de 14.

Para aplicar esto, primero se procede a ligar los 3 ejes principales del marco teórico, la solución analítica, la inferencia bayesiana, y las cadenas de Markov con el algoritmo de Metropolis-Hastings.

5.1. Implementación de las cadenas de Markov en la solución de analítica

Los parámetros libres de las que depende la solución de Cerfon [3] son $\{\varepsilon, \kappa, \delta, A\}$, así que estos son los parámetros que se quieren conocer. De esta manera entonces definimos un estado $H = j$ como $H_j = \{\varepsilon_j, \kappa_j, \delta_j, A_j\}$, este H_j es un posible estado del espacio de configuraciones (muestras) de H. A su vez, este es el vector de parámetros que queremos conocer de la sección 4.2, y $\{D_u\}$ son los datos observados, o sea los producidos por el vector H verdadero, que en este caso se les introduce ruido gaussiano para emular mediciones reales. A su vez, véase que entonces la distribución de probabilidad a la que se desea llegar es la que está dada por la ecuación 16, que comparando con la ecuación 23, vemos que la probabilidad estacionaria π_j es la parte izquierda de la ecuación 16, b_j es el numerador de la derecha, y B el denominador.

$$\begin{cases} P\{H_j|\{D_u\}) = \pi_j \\ P\{H_j\}\prod_{u=1}^{N} P\{D_u|H_j\} = b_j \\ P\{\{D_u\}\} = B \end{cases} \tag{27}$$

De aquí siguiendo el procedimiento del algoritmo de Metropolis-Hastings 4.4, la matriz $\mathbf{Q}$ es la que hace variar el conjunto de parámetros H_j. Si la matriz de transiciones es simétrica ($q_{ij} = q_{ji}$), vemos que la función de aceptación $\alpha_{i,j}$ tiene su parámetro r dado por:

$$r = \frac{b_j}{b_i} = \frac{P\{H_j\}\prod_{u=1}^{N} P\{D_u|H_j)}{P\{H_i\}\prod_{u=1}^{N} P\{D_u|H_i)} \tag{28}$$

Para calcular r, se necesita $P\{D_u|H_j\}$, o sea, la "likelihood function", la cual usualmente distribuye como una Gaussiana [2]. Asumiendo que las mediciones son independientes y que el ruido gaussiano tiene varianza σ_u^2 [7], se obtiene que:

$$P\{D_u|H_j\} = \frac{1}{\sqrt{2\pi\sigma_u^2}} \exp\left(-\frac{(D_u - d_u(H_j))^2}{2\sigma_u^2}\right) \tag{29}$$

donde $d_u(H_j)$ es la predicción de los datos evaluando los parámetros de H_j en la solución analítica.

Con esto planteado, se procede a seguir el algoritmo de Metropolis-Hastings 4.4, haciendo algunos ajustes como se verá en la siguiente sección.

6. Metodología

Para implementar este algoirmo al problema, primero se genera una muestra de datos $\{D_i\}$, donde estos son la ubicación radial del borde del flujo, o sea su frontera, en diferentes puntos desde el eje de la coordenada toroidal (en este caso se fijó 12 puntos fijos a manera de detectores equidistantes angularmente). Esto se calcula usando la solución analítica de la sección 4.1, con valores escogidos arbitrariamente de $\varepsilon, \kappa, \delta$ y A que componen H_{real}. A estos datos, se les añade ruido gaussiano con un σ igual para todos por simplicidad para este trabajo.

Después de esto se propone una función de transición que cambie los cuatro parámetros al mismo tiempo, que sería el equivalente a la matriz de transiciones $\mathbf{Q}$ para los parámetros continuos. Para esta implementación se usó una distribución gaussiana centrada en el parámetro actual sobre el que se está aplicando el cambio, puesto que cumple que la probabilidad de ir desde el estado actual i al futuro j, es la misma que ir del estado futuro j al actual i, de manera que la probabilidad de transición es simétrica, para que al calcular esto en la función de aceptación 26, se cancelen y solo dependa de los $\pi_{i/j}$.

Con respecto a esta función de transición, cabe aclarar que la variación de cada tipo de parámetro es independiente del resto. Esto se implementó definiendo un σ_{param} llamado *rango de variación* (realmente es la desviación estándar) para cada parámetro, el cual se fue ajustando para obtener una tasa de aceptación del 20 % al 40 % para propuestas físicamente válidas. Estos ajustes se hicieron para el caso de los parámetros del ITER con un $\sigma = 0.03$ de ruido gaussiano en los datos y 60000 pasos con un descarte del 20 %. El σ_{param} usado después de los ajustes fue de 0.03 para ε, 0.09 para κ y 0.02 para δ y A.

Ahora se propone un estado inicial H_0, donde sus parámetros asociados se definene de manera aleatoria. Algo importante a destacar es que como estos parámetros representan cantidades físicas, estos no pueden tener

cualquier valor, sino que van en un rango de posibles valores dados por como es su definición. De esta manera cada parámetro tiene sus valores acotados de la siguiente manera [3]:

$$\begin{cases} 0 < \varepsilon < 1 \\ 0 < \kappa \\ -sin(1) < \delta < sin(1) \\ A \in \Re \end{cases} \tag{30}$$

Sin embargo, para el caso de κ y A, puesto que no tiene un rango tan acotado, se restringen de manera arbritraria comparando con el rango usual que tienen, por lo tanto se usó en el programa de la MCMC que $0 < \kappa < 15$, y que $-3 < A < 3$.

Posterior a esto, para la función de aceptación, el valor de $P\{H\}$ se le da un valor a priori arbitrario de 1 si los parámetros son físicamente viables, o sea, si estos se encuentran dentro del rango antes establecido, y 0 si no lo están. De esta manera se evita que se hagan evaluaciones sobre la solución analítica donde la función diverge o da resultados no físicos, y por lo tanto, no son valores posibles para una reconstrucción válida.

A su vez, debido a que las "likelihood functions" son gaussinas, las cuales se multiplican entre si por la productoria de la fórmula de Bayes para N datos (ver 16), se generan valores muy pequeños, que al evaluar computacionalmente el denominador se llega a hacer 0 por errores de punto flotante. Para resolver esto se usó el logaritmo natural de 28, que simplificando con la probabilidad a priori de $H_{i/j}$ igual a 1, se llega a:

$$ln(r) = \sum_{u}^{N} \frac{1}{2\sigma_u^2} \left[(D_u - d_u(H_i))^2 - (D_u - d_u(H_j))^2 \right] \tag{31}$$

Debido a esto, al generar el número aleatorio U, también hay que aplicar el logaritmo natural sobre este.

Obtenido $ln(U)$ y $ln(r)$, se usa el criterio de Metropolis para aceptar o rechazar esta propuesta de parámetros, siendo esta entonces:

$$ln(U) < min(ln(r), 0) = \begin{cases} ln(r); & \text{si } ln(r) < 0 \\ 0; & \text{si } ln(r) \geq 0 \end{cases} \tag{32}$$

Si se cumple lo anterior, el estado propuesto es aceptado como el valor del siguiente estado, si pasa lo contrario, entonces el siguiente valor de la cadena es el mismo que el actual, siguiendo el algoritmo de Metropolis 4.4. Se realiza este procedimiento de manera reiterativa, hasta llegar al número de pasos máximo designado m.

Para el cálculo de los resultados de la cadena, se usa la propiedad de las cadenas de Markov 20, donde calculamos el lado izquierdo de la ecuación para obtener el valor de expectación de los estados según la PMF estacionaria π, y con esto obtener una aproximación al valor real de los parámetros originales.

7. Resultados preliminares

Para las siguientes secciones, la reconstrucción se realizó para los parámetros geométricos ε, κ y δ. Se tomó el parámetro A como conocido para toda la cadena, esto con el fin de evaluar unos primeros resultados para solo la parte geométrica.

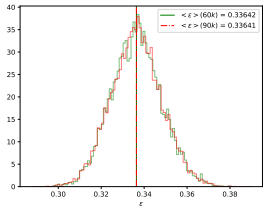
A su vez, no se toma en cuenta el primer 20 % de la cadena para cada conjunto de resultados debido al *burn-in*, por lo tanto cuando se reportan, por ejemplo 60000 pasos, la cadena validada para los resultados mostrados es de 48000.

7.1. Convergencia de la cadena

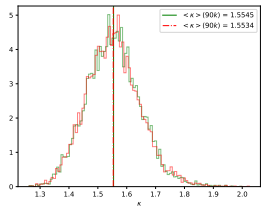
En la figura 1 se muestran los resultados de la cadena después 60000 y 90000 pasos, para el mismo conjunto de parámetros y con los mismo generadores de números pseudo-aleatorios (de ahora en adelante se dirá números aleatorios por simplicidad). Esta prueba se hizo para verificar que el resto de resultados que se hicieron con 60000 pasos son suficiente para obtener el comportamiento del estado estacionario de la cadena. Algo importante es que solo se tomaron los primeros 4 decimales para esta prueba para ver hasta cual estaba la diferencia entre las dos cadenas. Para el resto de resultados se usaron de 2 a 3 decimales en el valor reportado del promedio de la reconstruucción.

En la figura 2, se hizo una prueba para los mismos parámetros y con el mismo generador de números aleatorios para 60000 pasos. Pero en este caso con valores iniciales lejos de los valores reales, esto con el objetivo de ver la convergencia de la cadena. En específico, el vector inicial de la cadena tiene los valores de $\varepsilon_0 = 0.1$, $\kappa_0 = 10$, $\delta_0 = 0.80$ y $A_0 = -0.155$, con A constante en toda la cadena nuevamente.

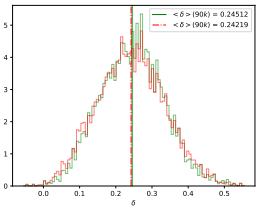
Como se puede observar, con 60000 pasos, el promedio obtenido de la cadena tiene la tendencia de la figura 1, lo que deja ver una buena convergencia de esta haacia el estado estacionario a pesar de usar valores iniciales lejos de este.



(a) Comparación para ε.

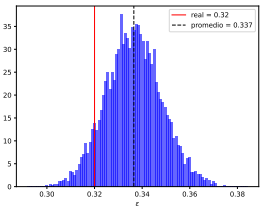


(b) Comparación para κ.

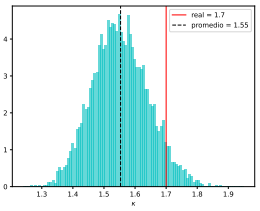


(c) Comparación para δ.

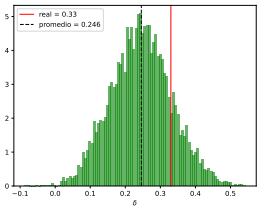
Figura 1: Comparación de la reconstrucción con 60000 y 90000 pasos de los parámetros geométricos con A conocido y fijo en ambas cadenas. Desviación estándar del ruido introducido a los datos: $\sigma = 0.03$



(a) Histograma para ε.



(b) Histograma para κ.



(c) Histograma para δ.

Figura 2: Prueba de convergencia de la cadena para 60000 pasos, con A conocido y fijo en la cadena. Desviación estándar del ruido introducido a los datos: $\sigma = 0.03$

7.2. Resultados de las reconstrucciones para los parámetros geométricos

Para la reconstrucción de los parámetros geométricos de ITER y de NSTX, se realizaron 3 pruebas para cada uno aumentando el ruido introducido a los datos originales. Los valores escogidos fueron $\sigma = 0.03$, 0.07 y 0.1. A su vez, ya no se fijó una semilla para los números aleatorios. Por último, nuevamente el parámetro de presión magnética A se sigue tomando como conocido, por lo tanto la reconstrucción solo se realiza para la parte geométrica.

7.2.1. Reconstrucción de los parámetros de ITER

En las figuras 3, 4 y 5 se pueden ver la reconstrucción para diferentes valores del ruido inicial de los datos, con un ruido de un 0.03, 0.07 y 0.1 respectivamente. Para los dos primeros casos, la convergencia de la cadena se aproxima bastante al valor real en los 3 parámetros geométricos. Esto se puede ver en la tabla I, donde la mayor diferencia con el el valor real para los tres parámetros es en el caso del ruido con $\sigma = 0.1$.

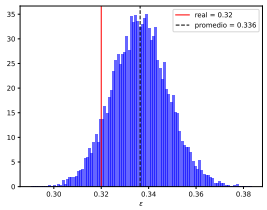
Para este caso de ruido, el valor recuperado de ε y κ se recuperan con bastante cercanía, sin embargo, esto no pasa para δ, donde su valor medio difiere en 0.563 de su valor real. A diferencia de los otros dos casos donde difiere del real con 0.085 y 0.17 respectivamente. Esto indica que el ruido a es enivel ya no deja distinguir correctamente cual es el valor aproximado para ese parámetro, debido a esto fue que no se hicieron más pruebas con mayor ruido, puesto que ya se perdió la información suficiente para poder recuperar el modelo original.

σ	ε	$\Delta\varepsilon$	κ	$\Delta\kappa$	δ	$\Delta\delta$
0.03	0.336	0.016	1.55	0.15	0.245	0.085
0.07	0.354	0.034	1.45	0.25	0.160	0.17
0.1	0.363	0.043	1.44	0.26	−0.233	0.563

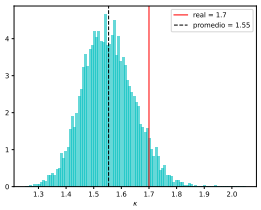
Cuadro I: Resumen de la reconstrucción de los parámetros geométricos para el caso del ITER y comparativa con los valores reales, siendo estos $\varepsilon = 0.32$, $\kappa = 1.7$ y $\delta = 0.33$. Δ(parametro) es la diferencia absoluta del valor promedio de la cadena con el real.

7.2.2. Reconstrucción de los parámetros de NSTX

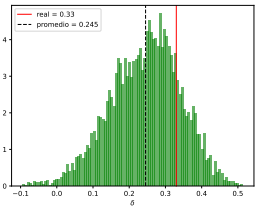
Para la reconstrucción de los parámetros de NSTX ocurre algo similar que en el caso de ITER, donde para los dos valores del ruido más bajos, la convergencia de la cadena obteniene de manera cercana los valores reales para los tres parámetros geométricos. De igual forma,



(a) Histograma para ε.

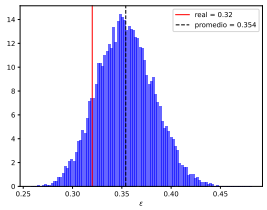


(b) Histograma para κ.

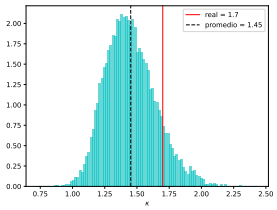


(c) Histograma para δ.

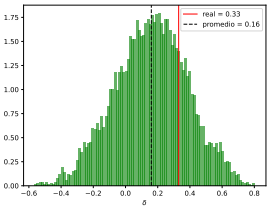
Figura 3: Reconstrucción de parámetros geométricos para el caso de ITER. Desviación estándar del ruido introducido a los datos: $\sigma = 0.03$



(a) Histograma para ε.



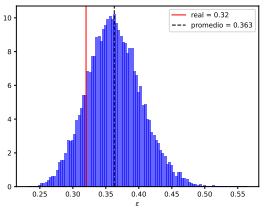
(b) Histograma para κ.



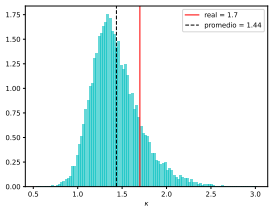
(c) Histograma para δ.

Figura 4: Reconstrucción de parámetros geométricos para el caso de ITER. Desviación estándar del ruido introducido a los datos: $\sigma = 0.07$

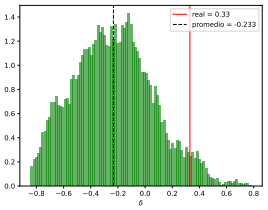
para el caso de ruido de $\sigma = 0.1$, la diferencia para δ es muy grande en comparación al rango de sus valores posibles, lo que indica que no hay suficiente información en los datos para poder reconstruir correctamente este parámetro para este nivel de ruido.



(a) Histograma para ε.



(b) Histograma para κ.



(c) Histograma para δ.

Figura 5: Reconstrucción de parámetros geométricos para el caso de ITER. Desviación estándar del ruido introducido a los datos: $\sigma = 0.1$

σ	ε	$\Delta\varepsilon$	κ	$\Delta\kappa$	δ	$\Delta\delta$
0.03	0.797	0.017	1.91	0.09	0.317	0.033
0.07	0.818	0.038	1.83	0.17	0.28	0.07
0.1	0.833	0.053	1.76	0.24	0.229	0.121

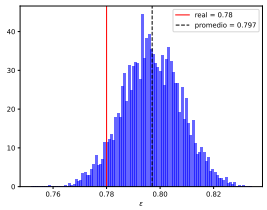
Cuadro II: Resumen de la reconstrucción de los parámetros geométricos para el caso de NSTX y comparativa con los valores reales, siendo estos $\varepsilon = 0.78$, $\kappa = 2$ y $\delta = 0.35$. Δ(parametro) es la diferencia absoluta del valor promedio de la cadena con el real.

8. Conclusiones preliminares

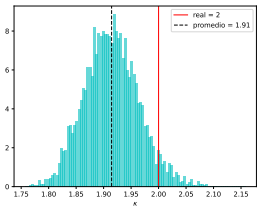
Se conluyó que la implementación del algoritmo de Metropolis-Hastings usado para este trabajo converge correctamente para valores de los parámetros físicamente válidos. Esto permitió reconstruir los parámetros geométricos para el caso del ITER y de NSTX para diferentes niveles de ruido en los datos sintéticos generados para cada uno de los casos.

A su vez, se observó como para ambas configuraciones, al hacer la prueba con ruido con $\sigma = 0.1$ el valor de δ predicho por la cadena está muy alejado del valor real considerando el rango de valores que δ puede tener. Una posible explicación a esto es que la información que proveén los datos sobre el valor real de δ es muy baja, lo que no permite al algoritmo encontrarlo.

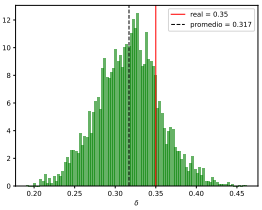
Otro aspecto que se observó, es que el promedio para



(a) Histograma para ε.

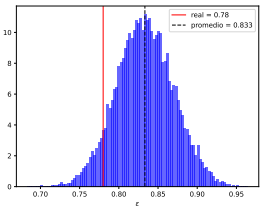


(b) Histograma para κ.

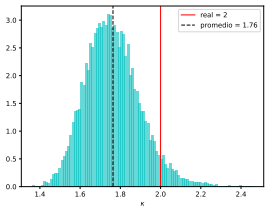


(c) Histograma para δ.

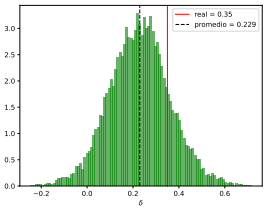
Figura 6: Reconstrucción de parámetros geométricos para el caso de NSTX. Desviación estándar del ruido introducido a los datos: $\sigma = 0.03$



(a) Histograma para ε.

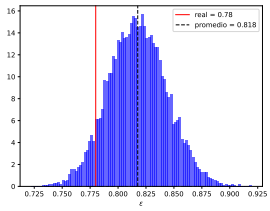


(b) Histograma para κ.

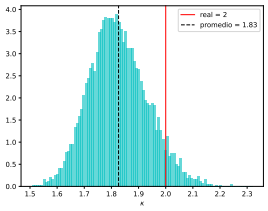


(c) Histograma para δ.

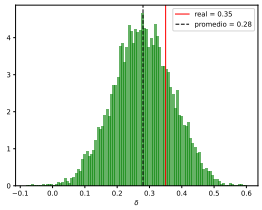
Figura 8: Reconstrucción de parámetros geométricos para el caso de NSTX. Desviación estándar del ruido introducido a los datos: $\sigma = 0.1$



(a) Histograma para ε.



(b) Histograma para κ.



(c) Histograma para δ.

Figura 7: Reconstrucción de parámetros geométricos para el caso de NSTX. Desviación estándar del ruido introducido a los datos: $\sigma = 0.07$

todos los casos probados tiene la tendencia de ser mayor para ε con respecto al valor real, y de ser menor para κ y δ, lo cual llama la atención, puesto que tanto el ruido de los datos, el punto inicial de la cadena y el conjunto de parámetros propuestos en cada paso son obtenidos de manera aleatoria. Esto es un resultado que hay que analizar su aparición puesto que nose pudoo concluir nada sobre esto.

Finalmente, debido a la mala reconstrucción del parámetro δ para el ruido con 0.1 de desviación estándar, se concluyó que la implementación es eficaz para los parámetros geométricos con incertidumbres de menos del 10 %. Esto puede mejorar probando otros ajustes del σ_{param} relacionado a δ y el número de pasos total m, caso que queda pendiente de probar.

8.0.1. Sugerencias

El objetivo de este trabajo es la reconstrucción de los 4 parámetros, sin embargo, por el momento solo se tiene la parte geométrica, faltando el parámetro A, relacionado con el campo magnético del plasma, y por ende, con la relación de la presión térmica y la magnética. A su vez, al añadir A como otro parámetro que encontrar, posiblemente se tenga que incrementar el número de pasos necesarios, por lo que se deberá hacer nuevas pruebas de convergencia de la cadena para estos nuevos resultados.

Por otro lado, encontrar otros valores para la variación de cada parámetro puede resultar en obtener resultados más cercanos a los valores reales, lo que puede mejorar la eficacia de esta implementación.

Referencias

[1] J. Svensson and A. Werner, in *2007 IEEE International Symposium on Intelligent Signal Processing* (IEEE, 2007) pp. 1–6.

[2] A. Merlo, A. Pavone, D. Böckenhoff, E. Pasch, G. Fuchert, K. J. Brunner, K. Rahbarnia, J. Schilling, U. Höfel, S. Kwak, *et al.*, Journal of Instrumentation **18** (11), P11012.

[3] A. J. Cerfon and J. P. Freidberg, Physics of Plasmas **17** (2010).

[4] H. Grad and H. Rubin, in *Proceedings of the second United Nations international conference on the peaceful uses of atomic energy. V. 31. Theoretical and experimental aspects of controlled nuclear fusion*, INIS-XU–021 (1958) pp. 190–197.

[5] L. Solov'ev, Sov. Phys. JETP **26**, 400 (1968).

[6] S. Ross, in *Simulation (Fifth Edition)* (Academic Press, 2013) fifth edition ed., pp. 271–302.

[7] G. Von Nessi, M. Hole, and M. team, Journal of Physics A: Mathematical and Theoretical **46**, 185501 (2013).